Análise exploratória de pedidos do marketplace Olist (2017-2018)

Aluno: Guilherme Henrique Braga e Silva

1. Contexto e fonte dos dados

O trabalho analisa o *Brazilian E-Commerce Public Dataset by Olist*, que reúne cerca de 100 mil pedidos feitos entre 2016 e 2018 em um marketplace brasileiro, distribuídos em várias tabelas relacionadas (pedidos, itens, pagamentos, avaliações, clientes e produtos). Foram usadas 7 das 9 tabelas; geolocalização e vendedores não eram necessárias às perguntas. O objetivo é entender a evolução das vendas, a concentração da receita, o efeito do atraso na satisfação do cliente e as diferenças regionais de prazo e frete.

2. ETL e qualidade dos dados

O pipeline (ingestão, diagnóstico, limpeza e gravação em *data/processed/*) foi organizado em módulos Python, mantendo os dados brutos intactos. O diagnóstico inicial das tabelas brutas foi:

Tabela	Linhas	Valores nulos	Duplicatas (linha inteira)	Colunas com tipo inadequado
pedidos	99.441	4.908	0	5 (datas como texto)
itens	112.650	0	0	1 (data)
pagamentos	103.886	0	0	0
avaliacoes	99.224	145.903	0 (814 review_id repetidos)	2 (datas)
produtos	32.951	2.448	0	0
clientes	99.441	0	0	0

Decisões tomadas e justificativas:

- **Tipos:** as 8 colunas de data foram convertidas para *datetime*; sem isso não seria possível calcular prazos nem agrupar por mês.
- **Nulos em datas de entrega** (2.965 pedidos, 3,0%): mantidos, pois indicam pedidos cancelados ou ainda não entregues (a ausência tem significado). Apenas 8 pedidos com status *delivered* estavam sem data de entrega; ficam fora só dos cálculos de prazo.
- **Avaliações:** título (88,3% nulo) e mensagem (58,7% nulo) foram descartados por não serem usados; 547 pedidos tinham mais de uma avaliação, mantendo-se a mais recente (551 linhas removidas) para garantir uma linha por pedido.
- **Pagamentos:** 9 registros inválidos (valor zero / tipo *not_defined*) removidos. **Produtos:** 610 sem categoria viraram *unknown* (1,3% da receita), e as categorias foram traduzidas pela tabela oficial do dataset.
- **Outliers (IQR):** 7,5% dos preços e 10,8% dos fretes ficam fora dos limites, mas foram **mantidos**: são valores legítimos de uma distribuição assimétrica (Figura 1). Usei mediana e escala logarítmica em vez de removê-los.
- **Tabela analítica:** uma linha por pedido (99.441 x 23 colunas), com variáveis derivadas: *dias_entrega*, *dias_atraso* (entrega real menos data prevista), *ano_mes* e *valor_total*. Os nomes originais do Kaggle foram mantidos nas demais colunas, para rastreabilidade com o dicionário do dataset. As análises usam apenas pedidos *delivered* (96.478; 97,0%).

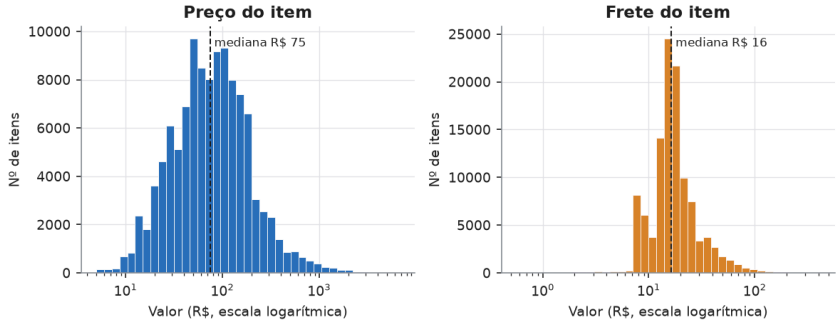


Figura 1 – Distribuição de preço e frete por item (escala logarítmica). Linha tracejada: mediana.

3. Perguntas de pesquisa e resultados

P1. Como evoluíram os pedidos e a receita ao longo do tempo?

A série foi limitada a jan/2017–ago/2018, período contínuo (em 2016 os registros são esparsos). A receita mensal de produtos passou de R$ 112 mil em jan/2017 para R$ 839 mil em ago/2018. Comparando os mesmos meses (jan–ago), a receita cresceu **141%** de 2017 para 2018 (R$ 3,0 mi para R$ 7,2 mi) e o número de pedidos cresceu 140%. Como o ticket médio ficou estável (entre R$ 124 e R$ 149), o crescimento veio do **volume** de pedidos, não de preços maiores. O pico foi em nov/2017 (R$ 988 mil, +52% sobre outubro), compatível com a Black Friday (24/11/2017), embora essa explicação não tenha sido testada. Em 2018 a receita se estabiliza entre R$ 826 mil e R$ 978 mil por mês.

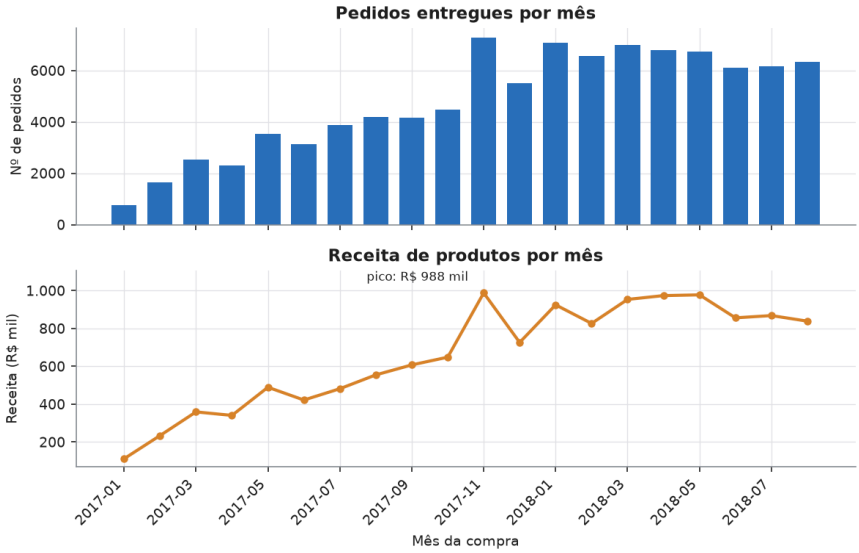


Figura 2 – Pedidos entregues e receita de produtos por mês (jan/2017 a ago/2018).

P2. Quais categorias concentram a receita?

Das 74 categorias, as cinco maiores respondem por **39,8%** da receita: *health_beauty* (9,3%), *watches_gifts* (8,8%), *bed_bath_table* (7,7%), *sports_leisure* (7,2%) e *computers_accessories* (6,7%). Apenas 18 categorias (24%) reúnem 80% da receita, uma concentração típica de Pareto. Receitas parecidas escondem perfis diferentes: *watches_gifts* vende poucos itens caros (5.859 itens, preço médio R$ 199), enquanto *bed_bath_table* vende muitos itens baratos (10.953 itens, R$ 93).

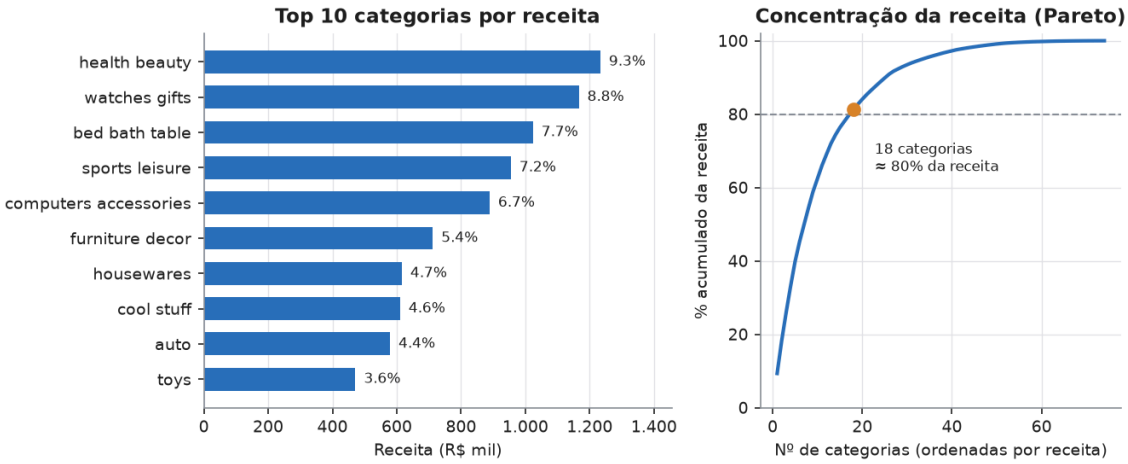


Figura 3 – Top 10 categorias por receita e curva de concentração (Pareto).

P3. Atrasos na entrega reduzem a nota de avaliação?

Sim, e de forma muito intensa. Dos 95.824 pedidos entregues e avaliados, 8,0% chegaram depois da data prevista. A nota média cai de **4,29** (no prazo) para 3,77 (1 a 3 dias de atraso), 2,32 (4 a 7 dias) e **1,73** (mais de 7 dias). A parcela de avaliações negativas (notas 1 e 2) vai de 9,2% para 19,1%, 61,3% e **78,4%**. A correlação de Spearman global é fraca (-0,18) porque 92% dos pedidos chegam no prazo; o efeito se concentra nos atrasados. Trata-se de associação observada, não de prova de causalidade.

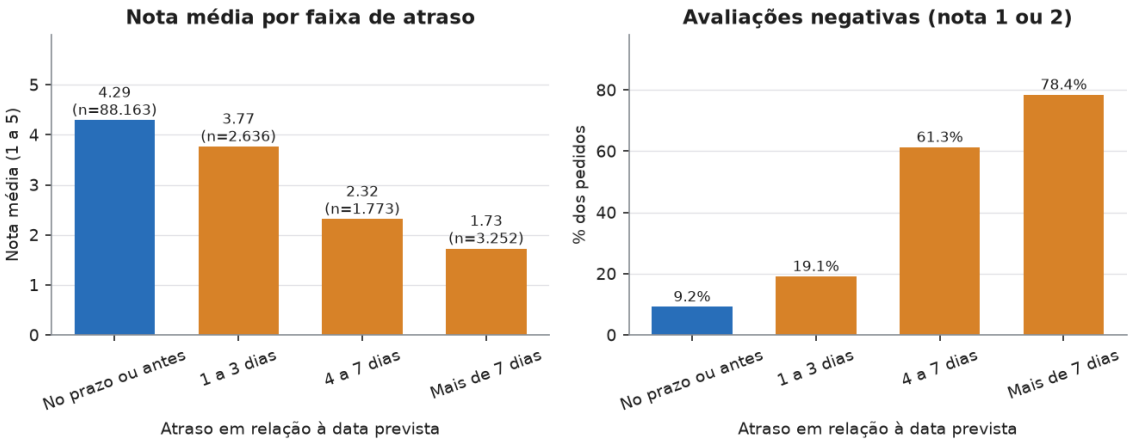


Figura 4 – Nota média e percentual de avaliações negativas por faixa de atraso.

P4. Estados mais distantes têm entrega mais lenta e frete mais caro?

Entre as 24 UFs com pelo menos 100 pedidos, o prazo médio vai de **8,8 dias** em SP (frete mediano R$ 13,61) a **26,4 dias** no AM. A correlação entre prazo e frete é moderada-forte (Pearson 0,74), mas o frete não depende só do prazo: RO, PB, MA e TO têm frete mediano acima de R$ 34 com prazos menores que os do AM e do PA (frete de R$ 27 a R$ 29). O percentual de atrasos também varia: 5,9% em SP contra 23,9% em AL.

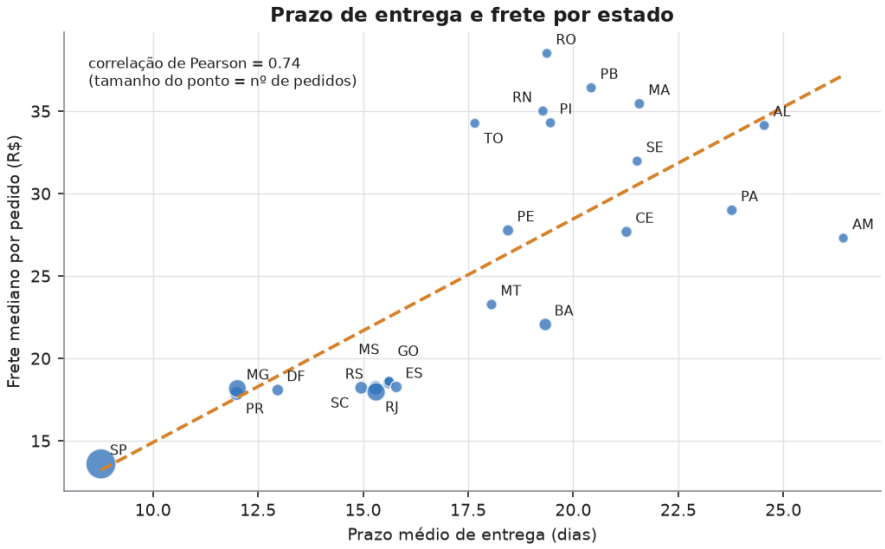


Figura 5 – Prazo médio de entrega x frete mediano por UF (tamanho do ponto = nº de pedidos).

4. Conclusões

- O marketplace cresceu por **volume**: a receita de jan–ago mais que dobrou de 2017 para 2018, com ticket médio estável, e estabilizou em 2018.
- A receita é concentrada (24% das categorias geram 80%), mas com modelos distintos de venda: itens caros e poucos versus baratos e muitos.
- O **cumprimento do prazo** é o fator mais associado à satisfação: pedidos com mais de 7 dias de atraso recebem nota 1 ou 2 em 78% dos casos.
- Há forte desigualdade regional: estados do Norte e Nordeste têm prazos mais longos e fretes maiores, e os maiores índices de atraso estão no Nordeste (AL, MA, PI, CE, SE), um ponto de melhoria logística.

5. Limitações

- Dados de 2016–2018 de um único marketplace; os padrões podem não se manter hoje nem em outras empresas.
- Análise observacional: associações (como atraso e nota) não provam causalidade. Só quem decide avaliar aparece nas notas, o que pode enviesar o resultado.
- A receita considera apenas o preço dos produtos de pedidos entregues (sem frete e sem cancelados); a categoria de um pedido é a do item mais caro.
- O frete por pedido depende de peso, volume e nº de itens, que não foram controlados. Três UFs com menos de 100 pedidos ficaram de fora da P4.

Fonte dos dados

Olist. *Brazilian E-Commerce Public Dataset by Olist.* Kaggle. Disponível em: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce. Acesso em: 31 out. 2026. Código e instruções de execução: README.md (pasta do projeto).